李若诗

电话：18833401985　　申请岗位：大模型训练和部署
邮箱：1670982279@qq.com　　实习时间：三个月以上

教育背景

2022.09 - 2026.06　**哈尔滨工业大学(威海)**　**信息科学与工程学院**　**电子科学与技术专业**
2026.09 – 2029.03　**上海交通大学**　**集成电路学院（信息与电子工程学院）**　**电子信息（保研）**
综合成绩：97.77/100　本科综合排名：2/91　英语水平：CET4　548/CET6　543
主修课程：电路基础（100），微电子器件原理（98），嵌入式系统及应用（99），数字信号处理（99），信号与系统（94）数字逻辑电路与系统（97），Verilog 数字系统设计（97）,概率论与数理统计（98），复变函数与积分变换（98）

科创竞赛

2025.12 – 2026.01　**基于开源架构的端到端大模型全栈开发**　**开源项目**

学习**大模型部署**,使用**阿里云 PAI-DSW** 部署好浪潮源大模型的服务端和一个 Streamlit 开发的客户端实现智能编程助手；了解大模型**检索增强生成**，实现使用开源大模型完成 RAG 知识库的构建；学习**大模型微调（LoRA/QLoRA）**，完成微调后模型的效果测试和调优。实现一个论文检索系统的完整 AI 模型部署和优化。

2025.09 – 2026.05　**硬件感知的大模型/神经网络自动化压缩与优化研究**　**毕业设计**

针对特定的硬件设备和不同的神经网络结构实现自动化搜索相应的压缩方案。利用**强化学习**自动确定量化策略，采用硬件模拟器来产生直接的反馈信，可以为不同的神经网络架构和硬件架构**专门化量化策略**。使用 MobileNet 和 Imagenet 数据集和 **DDPG 算法**实现强化学习智能体对网络结构的搜索和压缩。为部署轻量级 AI 模型和实现硬件加速器设计打下基础。

2025.01 – 2025.05　**AI 加速器可靠性设计**　**项目组员**

针对在轨 AI 系统因 SEU 效应导致的识别准确率下降问题，使用 PyTorch 框架搭建了多种卷积神经网络模型，包括 采用传统卷积与 Winograd 卷积的 VGG19 和 ResNet18 等模型，选择操作级故障注入平台，进行更精细的可靠性分析。加深对卷积算子（Winograd）的底层理解和掌握 PyTorch 框架下的容错验证，增强可靠性部署能力。

2023.08 - 2024.08　**基于 vLLM 的大模型推理服务优化与量化性能分析**　**实践项目**

成功部署 Qwen1.5-7B-Chat 等主流大模型，并利用 vLLM 框架实现高并发推理服务，通过 PagedAttention 机制显著提升吞吐量。对比研究 FP16、AWQ (4-bit) 和 GPTQ (4-bit) 等多种量化方案对模型推理性能的影响，量化分析其在不同并发请求下的 吞吐量 (TPS) 和 首字延迟 (TTFT)。掌握了从模型量化、服务部署到性能评估的端到端大模型推理优化流程，具备解决实际部署挑战的能力。

荣誉奖励

2023-2024 年度**国家奖学金**	2024.10	2024-2025 年度**国家励志奖学金**	2025.10
全国大学生机器人大赛 RoboMaster2024 机甲大师超级对抗赛**全国二等奖**			2024.08
全国大学生智能汽车竞赛全国赛单车越野组**全国二等奖（队长）**			2023.08
山东省大学生物理竞赛**一等奖**	2024.12	山东省大学生光电竞赛**电学组一等奖**	2024.11
全国大学生智能车竞赛山东赛区二等奖	2023.10	全国大学生数学竞赛黑龙江赛区二等奖	2023.11
哈尔滨工业大学 2022-2023 年度优秀学生干部	2023.11	2023-2024 年度五四表彰优秀团员	2024.05

个人技能

- ✓ 熟悉 Python 和 C 语言，具备一定的编程能力，对大模型有基本的了解。了解深度强化学习，熟悉 PPO/MPO 等算法。
- ✓ 熟悉常用的机器学习框架，如 TensorFlow、PyTorch 等，具备大模型微调和强化学习训练经验。
- ✓ 熟悉 DeepSpeed/Megatron-LM (训练优化)、vLLM/TensorRT-LLM (部署)、PEFT (微调)、Quantization (量化)等
- ✓

在校经历

2022.10 – 2025.10	哈工大（威海）书院建设发展中心	主席
2023.08 – 2026.06	哈工大（威海）2202602 班	学习委员
2022.11 – 2023.07	哈工大（威海）志愿服务中心	部长